

面向可审计实体关系抽取的溯源保持与证据门控知识图谱增强

匿名作者（中文核对稿）

摘要

引言：图谱增强抽取可以提供有用的关联，但检索到的关联并不必然是当前句子明确陈述的事实。生成模型还难以把预测关系追溯到具体原文跨度，也难以解释某一结果为何被接受；当断言进入安全相关知识系统时，这一缺口尤其重要。

方法：针对上述问题，本文提出保持溯源的证据门控框架，将图谱引导的候选生成与结果接受分离。仅由训练标注构建的图谱向经 QLoRA 适配的 Qwen3-4B 抽取器提供有界概念与关系提示；随后通过确定性跨度重建、实体接受和关系验证，仅保留具有原文链接且满足类型约束的断言。本文在 ADE 和 CoNLL04 上采用统一严格字符跨度协议评估，并先报告两个数据集的分布特征。

结果：已完成的测试比较显示，溯源门控系统在两个基准上的关系 F1 均高于配对的纯源生成器，并记录了明确的接受决策。在所报告的 CoNLL04 敏感性分析中，移除训练—测试文本完全重合句后，关系改进仍然存在。

讨论：结果支持将受控图谱增强作为面向人工复核的可审计抽取层。门控仅建立结构准入和原文链接，不能证明语义真值或临床因果，也不代表普遍准确率领先；最强监督基线在总体抽取 F1 上仍具有竞争力。

关键词：实体关系抽取；知识图谱；溯源；证据落地；药物不良反应；选择性预测

1 引言

结构化信息抽取连接非结构化文本与可检索的实体、类型关系及下游知识系统。在安全相关应用中，抽取关联还必须可供检查：使用者需要知道识别的是哪一个提及、哪一句原文支持该关系，以及哪些处理步骤产生了最终断言。药物不良反应抽取直接体现了这一要求。即使输出结构合法，模型若识别出药物和不良反应后虚构二者之间的关联，仍会形成误导性记录。通用信息抽取则在更丰富的实体和关系类型上，对同一技术问题提供补充检验。

神经实体与关系模型已经为识别问题提供了有效方法 [1, 2]。生成式模型允许在不同标签集合间复用统一的结构化输出格式，但流畅生成不保证预测对象受到输入支持 [3]。当抽取三元组进入知识图谱后，错误可能被后续检索或推理使用，从而超出原始句子的范围传播。

知识图谱能够提供类型化领域先验 [4]，检索增强使模型无需完全依靠参数记忆即可访问这些先验 [5]。与此同时，它引入了事实依据的权威性问题：训练句中出现过的关系可以提示应寻找什么，却不能证明新句子也具有该关系。训练图谱还可能返回当前训练样本自身的标注，或暴露跨划分共享内容。因此，研究问题不仅是图谱是否提高召回率，还包括上下文是否有资格进入提示，以及其作用是否能够得到控制与审计。

本文采用分阶段架构处理这一问题。纯源、精确锚点和高召回图谱条件生成器分别训练，形成输入条件的配对比较。确定性关系验证器检查结构与原文证据条件，互补的实体门控通过生成器一致性、原文匹配锚点或验证关系端点接受部分候选。最终系统将接受实体与端点存活的验证关系组合。本文使用已有表示和适配技术，贡献在于对这些组件的受控组合，而不是新骨干模型或新的优化算法。

本文聚焦 ADE[6] 和 CoNLL04[7]。ADE 是药物安全相关抽取任务，包含两种实体与一种关系标签；CoNLL04 作为通用领域对照，包含四种实体与五种有向关系标签。二者均使用英文句级输入，使研究可以聚焦抽取与验证机制，而不混入长文档窗口构造问题。两个数据集分别训练、分别评估，本实验不是从一个数据集直接迁移到另一个数据集的零样本迁移实验。

主要贡献包括：

- 提出带溯源约束的图谱上下文策略，仅使用训练标注，排除当前样本独有支持的候选，并对训练与评估文本完全重合的句子清空图谱提示。
- 以确定性方式组合原文跨度重建、实体选择和关系验证，保留带证据链接的断言，记录接受或拒绝预测的原因。
- 提供可复现的双基准分析，将划分与标签统计、统一严格跨度计分、验证集消融、已完成测试比较和完全重合文本敏感性分析联系起来。

本文面向分析人员使用的知识系统提供可审计抽取层，不将基准关系标签直接解释为临床因果，不输出经过校准的风险概率，也不据此宣称自主安全决策已经得到验证。

2 相关工作

2.1 联合实体关系抽取

实体识别必须同时解决提及边界与类型，关系抽取还依赖正确恢复有方向的类型端点 [1]。在该任务中，全局一致性约束具有较长研究历史，CoNLL04 对应的研究即采用全局推断形式 [7]。SpERT 枚举候选跨度，利用预训练 Transformer 联合建模实体与关系 [2]。由于其完成相同联合任务而不依赖生成式 JSON 接口，它是重要对照。本文从干净基础编码器重新训练 SpERT，采用相同训练划分，不使用可能包含开发集数据的已发布任务检查点。

GLiNER 和 GLiREL 分别提供标签条件实体识别与关系分类方案 [8, 9]。它们与本地微调生成器在监督方式、预训练和输出构造上不同，因此本文报告具体实现的训练集校准流水线，而不是对整个模型家族作穷尽性结论。同骨干零样本生成器进一步帮助区分本地适配与图谱条件的作用。

2.2 图谱上下文与约束生成

知识图谱显式表示实体与类型关系，检索增强将选中记录作为模型上下文 [4, 5]。GenIE 通过结构化输出空间和实体、关系目录约束生成式信息抽取 [10]。但目录合法性和原文支持是不同条件：一个合法实体或关系仍可能没有在当前输入中被陈述。因此，本文将图谱上下文视为候选先验，其准入取决于训练溯源与局部原文匹配。

BGE-M3 为语义模式检索提供冻结文本表示 [11]，它既不是图神经网络，也不与抽取器联合优化。QLoRA 支持 Qwen3 骨干的紧凑式适配 [12, 13]。但两者本身均没有定义候选是否应进入最终断言图谱，本文门控将这一接受策略显式化。

2.3 证据与安全相关知识构建

幻觉研究区分了结构良好的输出与忠实于原文的输出 [3]。事故报告的提示式图谱构建也说明了生成知识需要追踪原始来源 [14]。ADE 为药物安全相关关系任务提供了更受控的评估环境 [6]。不过，ADE 标签是文本关联标注，而不是针对患者的因果结论。本文评估抽取与已实现证据条件，不评估下游决策的医学或运行有效性。

3 数据集与分布分析

3.1 基准来源与划分

本文采用以 SpERT 格式发布的句级 ADE 和 CoNLL04 文件，计数对应这一预处理版本，而非原始来源语料中的全部句子。CoNLL04 保留其训练、开发与测试划分。ADE 文件包含 3,845 个训练句和 427 个测试句，从原始训练池中确定性划出 384 句作为开发集，剩余 3,461 句用于训练。划分以固定种子字符串 `public-full-42` 和原始记录标识符构造字符串，并按 SHA-256 摘要排序，而非依据验证表现选样。这是一个固定 ADE 划分，不是文献中部分研究所采用的多折均值。

表1由实际导入资产重新统计。软件称为文档的评估单元对应一个基准句子，并非完整病案或新闻文章。两套数据均为英文，因此实验不支持多语言或跨语言结论。发布标注直接导入，不是本项目重新标注的语料。

表 1: 实际实验划分的数据清单。依次列出数据集、划分、句数、实体数、关系数与平均长度；长度为重建原文中的空白分隔词元数。

Dataset	Split	Sentences	Entities	Relations	Mean length
ADE	train	3461	8717	5470	21.17
ADE	validation	384	996	627	21.82
ADE	test	427	1126	724	21.24
CoNLL04	train	922	3377	1283	28.77
CoNLL04	validation	231	893	343	30.27
CoNLL04	test	288	1079	422	28.94

3.2 实体与关系标签分布

ADE 包含 Drug、Adverse-Effect 两种实体，以及 Adverse-Effect 一种关系。导入文件的端点方向是“不良反应指向药物”，本文保留该约定，不将其改成直觉上的“药物指向不良反应”。CoNLL04 的实体类型为 Loc、Org、Peop 与 Other，关系类型为 Work_For、Kill、OrgBased_In、Live_In 和 Located_In。

图1展示训练标签分布，表2列出每个划分的精确标签计数。ADE 仅有一种关系类型，减少了关系类别之间的混淆，但端点识别、方向和错误实体配对仍需解决。CoNLL04 的关系集合与实体角色更加多样。因此，ADE 取得较高总体 F1 不意味着药物安全推理天然比通用推理容易，二者的监督抽取任务规模与结构不同。

表 2: 导入文件的精确实体与关系计数，分别列出训练、验证和测试划分。

Dataset	Kind	Label	Train	Validation	Test
ADE	entity	Adverse-Effect	4631	529	616
ADE	entity	Drug	4086	467	510
ADE	relation	Adverse-Effect	5470	627	724
CoNLL04	entity	Loc	1219	322	427
CoNLL04	entity	Org	616	170	198
CoNLL04	entity	Other	455	118	133
CoNLL04	entity	Peop	1087	283	321
CoNLL04	relation	Kill	179	42	47
CoNLL04	relation	Live_In	330	91	100
CoNLL04	relation	Located_In	247	65	94
CoNLL04	relation	OrgBased_In	271	76	105
CoNLL04	relation	Work_For	256	69	76




图 1: 训练标注分布。每个子图分别以对应实体或关系总数为分母, 不将两种对象混合计数。颜色与填充纹理同时用于区分两个基准。

3.3 句长与覆盖范围

ADE 和 CoNLL04 的平均训练长度分别为 21.17 与 28.77 个重建词元，平均测试长度为 21.24 与 28.94。图2的累计分布展示全部三个划分，而非仅训练集。这些是描述性空白分隔词元数，不是 Qwen 分词器计数。跨导入划分的最大长度分别为 ADE 的 97 与 CoNLL04 的 118。

每个导入句子均至少有一条标注关系。这是所选基准文件的重要特点：它们不衡量以大量无关句为主的部署文本流上的误报表现。本文保留给定基准组成，没有为所报告测试额外构造无关系负例句。




图 2: 各划分的经验累计句长分布。长度来自确定性重建文本，句级输入未采用标注辅助的窗口选择。

3.4 划分重合与图谱上下文隔离

两个数据集分别使用各自训练标注构图。完全重合检查先对原文进行大小写折叠与空白压缩，再比较字符串。ADE 未发现训练—开发或训练—测试完全重合；CoNLL04 有 14 个开发句和 19 个测试句与训练文本相同。对这些句子，在生成前同时清空精确锚点和高召回图谱上下文。

清空图谱提示不能撤销生成器对重复训练文本的学习。因此，主比较保留发布划分，另外使用固定预测，排除 19 个重合 CoNLL04 测试句进行敏感性分析。本文不宣称该基准具有重复簇隔离，也不宣称完全匹配能发现全部近重复内容。

4 所提方法

4.1 原文落地表示

设句子 x 由发布词元使用单个空格确定性连接。实体提及表示为

$$e = (b, u, y), \quad x[b : u] = m, \quad (1)$$

其中 $[b, u)$ 为字符区间, y 为实体标签, m 为复制的提及文本。关系 $r = (e_s, z, e_t)$ 包含有向、带类型的端点与关系标签 z , 对象另存来源标识与证据跨度。相同字符串位于不同偏移时仍是不同提及。公式(1)防止仅凭规范化名称便将错误出现位置计为正确。

导入基准为每条关系赋予 `explicit` 状态, 以其来源句作为证据跨度。这是表示约定, 不是新增的最小因果证据或不确定性标注。由于端点处于同一句输入, 证据共现在本实验中是相对较弱的条件。

4.2 架构与比较系统

图3展示流水线。SOE (纯源抽取)、EAE (精确锚点抽取) 和 HRGE (高召回图谱抽取) 在相同 Qwen3-4B 快照上分别训练 QLoRA 适配器。SOE 使用原文与训练推导本体, 不接收图谱提示; EAE 接收保守概念提示; HRGE 接收有界锚点、边先验和语义关系模式。

EVGE (证据验证图谱抽取) 对 HRGE 应用关系验证器。CFE (保守融合抽取) 将接受的 HRGE 实体与端点过滤后的原始 HRGE 关系组合。PGE (溯源门控抽取) 则将相同实体集合与端点过滤后的验证关系组合。这三者是确定性后处理变体, 而非额外训练网络。部署 PGE 需要 EAE 与 HRGE 候选, SOE 只作为比较分支, 不参与融合。

4.3 溯源受控图谱上下文

训练图谱存储提及字符串、类型、有向关系和支持句标识。对训练句 d , 如果候选只有 d 这一支持来源, 则将其排除。存在其他支持句的候选仍有资格保留, 其聚合支持统计不会按完整留一法重新构图。因此, 该策略不应被解释为完全删除当前样本对所有统计量的贡献。

EAE 最多使用 20 个类型平衡的精确概念提示。HRGE 具有三个上下文通道: 第一, 原文匹配锚点须满足 0.8 的经验类型纯度及至少 4 字符的英文长度条件; 第二, 类型边先验须在当前样本之外得到支持, 且两个端点字符串都在当前原文中出现; 第三, 冻结 BGE-M3 检索语义相关的关系模式记录。设 $\mathbf{H}$ 存储合格记录的归一化向量, $\mathbf{q}$ 为归一化原文向量, 则

$$\mathbf{s} = \mathbf{H}\mathbf{q}, \quad \mathcal{I} = \text{TopK}_k\{i : s_i \geq \tau\}. \quad (2)$$

公式(2)排序的是候选上下文而非被接受的事实。冻结 HRGE 上限为 12 个锚点 (每类最多 2 个)、6 个边先验及 4 个余弦相似度不低于 0.72 的语义模式。提示明确将这些对象




图 3: 双基准实验架构。各数据集训练图谱提供候选上下文, 当前句子提供证据。三个独立适配器采用相同骨干配置。实体接受要求任一信号成立, 关系验证要求全部检查通过; PGE 只保留端点存活的验证关系。虚线框表示比较路径, 门控不是学习式网络。

称为候选提示；完全重合隔离规则优先于检索，对受影响的评估句清空全部图谱上下文。

4.4 紧凑生成与确定性重建

生成器输出实体标识、复制文本与类型，以及关系标识、有向端点引用、类型和显式状态，不要求模型计算原文偏移。确定性扩展将复制提及分配到句中出现位置并重建字符跨度，同时记录无法匹配的字符串与无效引用。这将候选生成与原文坐标处理分离。

三个生成器均训练 1 轮，批大小 1，梯度累积 4，学习率 2×10^{-4} 。QLoRA 使用秩 8、alpha 16、dropout 0.05、NF4 双重量化与 bfloat16 计算，适配注意力 q/k/v/o 及前馈 gate/up/down 投影，冻结骨干。AdamW 其余参数采用 PyTorch 默认值，无学习率调度器或预热。最大训练序列为 4,096 token，损失不包含提示 token。所有分支使用相同数据集划分，主比较的训练种子均为 42。

推理采用记录中的 4,096-token 输入上限、1,024-token 生成预算和 90 秒任务时限，在本地 GPU 上运行两个推理工作进程。骨干版本与输入哈希保存在产物清单中。失败任务视为空预测，而非从分母删除。实验使用完整给定句子，不采用标注指导的救援窗口或依赖标签的句子截断。

4.5 关系验证与实体接受

对关系类型 z ，训练标注推导允许的源类型集 S_z 与目标类型集 T_z 。实现检查 $y_s \in S_z$ 、 $y_t \in T_z$ ，不额外要求每个具体源目标类型组合曾共同出现。验证器 $V(r)$ 还检查端点引用存在且不同、关系类型已知、状态为显式、证据合法，以及两个端点字符串都出现在同一局部证据跨度中。接受关系集为

$$R_V = \{r \in R_H : V(r) = 1\}. \quad (3)$$

实体门控使用三个布尔信号：

$$A(e) = A_{\text{agree}}(e) \vee A_{\text{anchor}}(e) \vee A_{\text{endpoint}}(e), \quad E_A = \{e \in E_H : A(e) = 1\}. \quad (4)$$

一致性指 EAE 预测出大小写折叠、空白规范化后相同文本与类型；锚点支持要求同类型且经原文门控的 HRGE 锚点；端点支持表示该实体参与公式(3)保留的关系。公式(4)中的信号互补，但不是统计独立的证据，验证端点更不是第二位人工复核者的判断。句内规范化文本与类型重复的候选会被折叠。

令 $F(R, E)$ 仅保留两个引用端点均在 E 中存活的关系，则

$$G_{\text{CFE}} = (E_A, F(R_H, E_A)), \quad G_{\text{PGE}} = (E_A, F(R_V, E_A)). \quad (5)$$

公式(5)明确了原始关系融合与验证关系融合的区别。所有接受与拒绝决定均有记录。保留关系满足已声明规则，但规则本身不能证明句子真正陈述了模型提出的含义。

5 实验协议

5.1 研究问题与范围

本文考察 PGE 是否相对 SOE 改善严格实体、关系抽取；图谱上下文与确定性选择如何在开发集上发挥作用；以及移除完全重合句后优势是否保留。外部基线用于判断生成式设计与其他抽取模型家族相比的表现，而不是将超过 SOE 等同于达到最先进水平。

本文的双基准报告范围是在查看验证及已有测试结果之后事后收敛的，属于聚焦分析，并非对全部尝试领域的预注册代表性抽样。在已有协议中，模型与门控设置在测试开放之前冻结；SOE 和 PGE 在验证关系 F1 退化不超过 1 个百分点、完成性与证据检查通过后晋级。这是实用的点估计门槛，而不是统计非劣效检验。本文使用已完成的 seed 42 测试，不据此推断多种子稳定性。

5.2 基线与评估一致性

内部开发集比较包含六个命名系统。测试表包含两个晋级系统及三个已完成外部对照。Qwen3-4B 零样本使用同骨干但不加载本地适配器，并采用已记录的原文扩展和关系验证器。SpERT 从 bert-base-cased 出发，在相同训练划分上训练 20 轮，批大小 2，关系阈值 0.4；使用最终检查点，不挑选测试最优轮次。GLiNER+GLiREL 使用预测实体而非金标实体，关系校准局限于训练集内部子集，实体阈值为 0.5。这些配置不同，不构成等计算量比较。

记录中的 GLiREL 校准为 ADE 选择原始规范标签与 0.0 关系阈值，为 CoNLL04 选择自然语言化标签与 0.1 关系阈值。选择这些设置没有使用开发或测试金标。

主表全部预测使用同一个公开数据字符跨度评估器重新计分。实体键包含精确原文区间和类型，关系键包含两个带类型的有向端点键及关系标签。预测证据偏移必须在给定原文中有效，评估器不通过搜索规范化文本来补救缺失偏移。重复键只计一次，无效对象保留为未匹配预测，缺失任务视为空输出。对合并计数，定义

$$P = \frac{TP}{TP + FP}, \quad R = \frac{TP}{TP + FN}, \quad F_1 = \frac{2TP}{2TP + FP + FN}. \quad (6)$$

公式(6)在各数据集内跨句合并使用，不对单句 F1 再求平均。所有导入状态均为显式，因此带状态分数不构成独立的不确定性评估。统一评估器消除了旧重复处理方式导致的小幅分母差异，原始资产不变，另提供新旧计数对照报告。

5.3 统计与规则符合性分析

本文固定预测，以种子 20260830 对测试句进行 20,000 次配对 bootstrap，每次重新计算合并 F1。百分位区间描述该已完成模型对的句子抽样不确定性，不描述训练种子差异。区间为描述性结果，未进行多重比较校正，也不用于改变冻结模型或门控。

证据覆盖率与规则无效计数独立于抽取 F1 报告，采用评估器去重之前的预测对象作为分母。完全重合敏感性分析从两个系统中移除同一批测试句标识，不重新训练或生成。本次修订读取测试标签仅用于统计与计分，不用于图谱提示构造或阈值选择。

6 结果

6.1 已完成测试比较

表3给出统一评估器下的测试结果。ADE 上，PGE 将关系精确率从 80.62% 提高到 87.00%，召回率从 67.82% 提高到 72.10%，关系 F1 由 SOE 的 73.67% 提高到 78.85%。实体 F1 基本不变，分别为 87.97% 与 87.93%。因此，主要改善发生在关系抽取，而不是普遍改善实体提及识别。

CoNLL04 上，关系精确率由 54.61% 提高到 62.40%，召回率由 56.16% 提高到 57.82%，关系 F1 由 55.37% 提高到 60.02%；实体 F1 则由 83.83% 降至 83.20%。该次运行以部分实体覆盖为代价，获得了更好的关系精确率与召回率平衡。

表 3: 已完成测试比较，严格原文字符跨度微平均分数 (%)。Qwen3-ZS 为 Qwen3-4B 零样本加已记录验证器；GLiNER+GLiREL 仅在训练数据内校准。各数据集使用自身测试划分，本地训练系统采用 seed 42，所有行采用同一评估器重算。

Dataset	System	Ent. P	Ent. R	Ent. F1	Rel. P	Rel. R	Rel. F1
ADE	Qwen3-ZS + verifier	63.83	63.32	63.58	39.36	22.24	28.42
ADE	GLiNER + GLiREL	79.30	64.65	71.23	60.31	43.23	50.36
ADE	SpERT	90.65	92.10	91.37	82.19	86.05	84.08
ADE	SOE	92.21	84.10	87.97	80.62	67.82	73.67
ADE	PGE	92.89	83.48	87.93	87.00	72.10	78.85
CoNLL04	Qwen3-ZS + verifier	48.78	53.94	51.23	30.92	19.19	23.68
CoNLL04	GLiNER + GLiREL	60.78	14.37	23.24	13.79	3.79	5.95
CoNLL04	SpERT	88.61	89.43	89.02	71.01	68.48	69.72
CoNLL04	SOE	85.83	81.93	83.83	54.61	56.16	55.37
CoNLL04	PGE	86.04	80.54	83.20	62.40	57.82	60.02

SpERT 在已完成系统中取得最高实体与关系 F1：ADE 为 91.37% / 84.08%，CoNLL04 为 89.02% / 69.72%。PGE 改善了配对生成式基线，但没有超过该训练式跨度模型。同时，PGE 在两套数据的两类任务上均超过记录中的零样本与 GLiNER+GLiREL 流水线；后者结论仅适用于已实现标签映射和校准设置，并不意味着这些家族的所有配置均较差。

6.2 配对差异与不确定性

从未四舍五入计数计算，ADE 的 PGE 减 SOE 关系 F1 差异为 5.18 个百分点，配对 95% 区间为 [0.31,10.29]；CoNLL04 为 4.65 个百分点，区间 [0.04,9.12]。正点估计与主表改善一致，但区间较宽、下界接近零，应理解为对当前已完成测试预测的证据，而不是跨

种子的普遍保证。实体 F1 差异为 ADE 的 -0.04 个百分点, 区间 $[-1.75, 1.62]$; CoNLL04 的 -0.63 个百分点, 区间 $[-2.38, 1.04]$, 均不支持实体 F1 提高的结论。

6.3 开发集组件分析

表4区分开发集上的候选生成与确定性选择。ADE 的 HRGE 关系 F1 为 76.29%, 超过 SOE 的 73.16%; EVGE 与 HRGE 相同, PGE 与 CFE 相同, 说明关系验证器在这些变体中没有进一步删去关系。实体门控降低 HRGE 召回率, 最终 PGE 关系 F1 为 75.91%。因此, 不能将 ADE 全部增益归因于验证, 也不能宣称每个阶段都独立提高 F1。

CoNLL04 上, HRGE 关系 F1 为 58.26%, 低于 SOE 的 60.24%; 验证提高到 59.60%, 最终组合达到 60.19%。在开发集点估计上, 这与 SOE 基本持平, 而不是明显增益。门控后实体精确率提高, 召回率与 F1 降低。本文保留开发与测试表现的差异, 不以测试结果重新选择消融系统。

表 4: 统一严格跨度评估器下的开发集消融 (微平均%, seed 42)。这些行用于分析冻结架构, 不代表额外晋级的测试系统。

Dataset	System	Ent. P	Ent. R	Ent. F1	Rel. P	Rel. R	Rel. F1
ADE	SOE	89.25	82.53	85.76	78.82	68.26	73.16
ADE	EAE	90.49	81.22	85.61	80.84	67.30	73.46
ADE	HRGE	90.35	85.54	87.88	80.04	72.89	76.29
ADE	EVGE	90.35	85.54	87.88	80.04	72.89	76.29
ADE	CFE	90.48	83.94	87.08	81.39	71.13	75.91
ADE	PGE	90.48	83.94	87.08	81.39	71.13	75.91
CoNLL04	SOE	84.94	82.08	83.49	61.33	59.18	60.24
CoNLL04	EAE	83.71	82.87	83.29	58.10	60.64	59.34
CoNLL04	HRGE	82.35	81.52	81.94	60.06	56.56	58.26
CoNLL04	EVGE	82.35	81.52	81.94	62.99	56.56	59.60
CoNLL04	CFE	84.97	78.50	81.61	63.37	55.98	59.44
CoNLL04	PGE	84.97	78.50	81.61	65.08	55.98	60.19

6.4 规则符合性及其解释

测试 SOE 在 ADE 的 610 个关系对象中包含 31 个规则无效对象, 在 CoNLL04 的 436 个关系对象中包含 16 个。PGE 分别保留 600 与 392 个关系对象, 规则无效对象均为零。HRGE 的 ADE 无效关系已经为零; CoNLL04 的 413 个对象中只有 3 个无效关系。这些计数区分了候选本身质量与验证器的贡献。

两个测试集上, SOE、HRGE、PGE 测得的无支持证据计数均为零。由于证据是完整句子, 端点成功绑定之后容易满足共现。因此, 本实验没有证明将非零无支持率降低的效果, 而是展示显式证据绑定与规则符合。基于金标的 F1 衡量另一性质: 类型关系是否与标注一致。

6.5 完全重合敏感性分析

移除 19 个训练—测试完全重合句后，CoNLL04 剩余 269 个测试句、1,023 个金标实体和 403 条金标关系。SOE 关系 F1 为 53.79%，PGE 为 59.10%，差异 5.31 个百分点；实体 F1 分别为 83.02% 与 82.90%。关系优势在排除这些重合句后仍保留。该分析处理的是完全重复文本，不覆盖所有语义重合或预训练污染。ADE 没有此类重合，敏感性结果与完整测试一致。

7 讨论

7.1 两个基准能够支持什么结论

共同结果是关系 F1 相对纯源生成有所提高，而不是普遍优于其他抽取架构。两个测试均伴随关系精确率提高，实体 F1 则相近或略降，这与控制候选接受、而非最大化输出量的设计相符。验证消融进一步说明图谱条件与选择会相互作用：召回导向上下文可在 ADE 中发挥作用，却不自动改善 CoNLL04；候选已满足规则时，验证器可能不执行额外过滤。

分布分析有助于解释数据集差异。ADE 训练池更大、平均句子更短、关系类型只有一种；CoNLL04 训练句更少、输入更长、关系标签有五种。这些因素同时变化，并未被实验独立隔离。它们与分数的关联支持分别报告数据集，但不能证明性能差距的因果来源。

7.2 可审计性是独立设计目标

系统可能在准确率上不及 SpERT，但仍为生成图谱对象提供可检查的接受机制。其价值在于完整路径可见：图谱支持说明为何建议候选，重建偏移说明出现位置，门控记录说明接受或拒绝原因。不过，该价值属于架构属性。当前实验没有用户研究来测量分析人员工作量减少、决策改善或信任提高，不能用完全规则符合替代这些证据。

门控还具有覆盖代价。一致性按规范化文本与类型判断，融合可能折叠重复提及，而评估器区分其偏移，因而可能丢失合法出现位置。合法端点类型和句内共现不足以证明关系含义，三个门控信号也不是三次独立确认。因此，最终输出仍是供复核的候选断言图谱。

7.3 对安全相关应用的启示

ADE 将实验连接到药物安全信息抽取，CoNLL04 则检验通用关系结构。框架可向分析人员同时呈现候选关系、来源句、类型端点及接受路径的溯源，再由分析人员接受、修订或拒绝。没有进入保留图谱，不能证明不良反应或其他现实关系不存在。

本任务止步于药物警戒判断、患者级因果归因或实际行动之前。两套数据均未验证风险传播、韧性评估或自主干预。扩展到这些应用，需要除抽取 F1 之外的任务结果指标

与专家评估。

8 局限性与负责任使用

聚焦且事后收敛的报告范围与单个完成训练种子限制了泛化。固定 ADE 划分不能直接等同于已发表多折结果。两套数据均为英文含关系句，多语言表现、长报告处理和无限制文本流上的误报率不在本实验范围内。若缺少上游文章标识，句级 bootstrap 不能恢复来自同一原始文章的句间依赖。

完全重合隔离防止为已知重复文本提供直接图谱提示，却没有消除训练暴露；敏感性分析只排除了已知完全重复。冻结预训练模型也可能接触过相关材料，当前产物不能排除这一点。本体的允许源类型集与目标类型集，弱于只允许真实观测联合类型对的约束。

1 轮生成器、20 轮 SpERT 与预训练标签条件模型不是等计算量基准。PGE 需要两套适配生成器和冻结检索，不能把紧凑适配等同于经过测量的端到端成本节省。本文没有新增临床标注或独立证据判断标签。数据与模型公开可得，也不意味着允许所有再分发或商业使用，原始许可证仍须遵守。

9 结论

本文提出溯源保持与证据门控图谱增强框架，在 ADE 和 CoNLL04 上评估。数据统计揭示了两个基准的标签与输入长度差异。统一严格跨度评估下，PGE 已完成测试的关系 F1 相对 SOE 分别提高 5.18 与 4.65 个百分点，同时提供明确的原文链接接受路径。CoNLL04 关系优势在移除训练—测试完全重合句后仍存在。SpERT 在总体抽取 F1 上仍更强，开发集消融也说明门控并非在孤立使用时始终有益。所支持的成果是面向人工复核的受控、可审计图谱增强抽取，而不是普遍准确率领先或自主安全推理已经验证。

致谢与资助

作者识别性资助与致谢信息随独立作者页提供，双盲正文中隐藏。

竞争利益声明

作者声明不存在可能影响本文工作的已知竞争性经济利益或个人关系。

数据与代码可用性

实验使用 SpERT 格式的公开 ADE 与 CoNLL04 数据。匿名复现材料将包含划分构造、数据统计、来源哈希、评估代码和派生结果表。数据正文与模型权重仍受原始许可证约束，识别性仓库链接在双盲阶段隐藏。

生成式人工智能与人工智能辅助技术使用声明

作者使用 OpenAI Codex 辅助代码检查、语言编辑、图表制作与论文组织。作者负责复核相关材料并对最终内容负责；作为研究系统评估的语言模型在方法中另行说明。

参考文献

- [1] J. Li, A. Sun, J. Han, C. Li, A survey on deep learning for named entity recognition, IEEE Transactions on Knowledge and Data Engineering 34 (1) (2022) 50–70. [doi:10.1109/TKDE.2020.2981314](https://doi.org/10.1109/TKDE.2020.2981314).
- [2] M. Eberts, A. Ulges, Span-based joint entity and relation extraction with transformer pre-training, in: ECAI 2020, IOS Press, 2020. [doi:10.3233/FAIA200321](https://doi.org/10.3233/FAIA200321).
- [3] Z. Ji, N. Lee, R. Frieske, T. Yu, D. Su, Y. Xu, E. Ishii, Y. J. Bang, A. Madotto, P. Fung, Survey of hallucination in natural language generation, ACM Computing Surveys 55 (12) (2023) 1–38. [doi:10.1145/3571730](https://doi.org/10.1145/3571730).
- [4] A. Hogan, E. Blomqvist, M. Cochez, C. D’Amato, G. de Melo, C. Gutierrez, S. Kirrane, J. E. L. Gayo, R. Navigli, S. Neumaier, A.-C. N. Ngomo, A. Polleres, S. M. Rashid, A. Rula, L. Schmelzeisen, J. Sequeda, S. Staab, A. Zimmermann, Knowledge graphs, ACM Computing Surveys 54 (4) (2021) 1–37. [doi:10.1145/3447772](https://doi.org/10.1145/3447772).
- [5] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W. tau Yih, T. Rocktäschel, S. Riedel, D. Kiela, [Retrieval-augmented generation for knowledge-intensive NLP tasks](https://arxiv.org/abs/2009.03582), in: Advances in Neural Information Processing Systems, Vol. 33, 2020, pp. 9459–9474.
URL <https://proceedings.neurips.cc/paper/2020/hash/6b493230205f780e1bc26945df7481e5-Abstract.html>
- [6] H. Gurulingappa, A. M. Rajput, A. Roberts, J. Fluck, M. Hofmann-Apitius, L. Toldo, Development of a benchmark corpus to support the automatic extraction of drug-related adverse effects from medical case reports, Journal of Biomedical Informatics 45 (5) (2012) 885–892. [doi:10.1016/j.jbi.2012.04.008](https://doi.org/10.1016/j.jbi.2012.04.008).

- [7] D. Roth, W. tau Yih, [A linear programming formulation for global inference in natural language tasks](#), in: Proceedings of the Eighth Conference on Computational Natural Language Learning, Association for Computational Linguistics, 2004, pp. 1–8.
URL <https://aclanthology.org/W04-2401/>
- [8] U. Zaratiana, N. Tomeh, P. Holat, T. Charnois, GLiNER: Generalist model for named entity recognition using bidirectional transformer, in: Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Association for Computational Linguistics, 2024, pp. 5364–5376.
[doi:10.18653/v1/2024.naacl-long.300](#).
- [9] J. Boylan, C. Hokamp, D. G. Ghalandari, GLiREL: Generalist model for zero-shot relation extraction, arXiv preprint arXiv:2501.03172 (2025). [doi:10.48550/arXiv.2501.03172](#).
- [10] M. Josifoski, N. D. Cao, M. Peyrard, F. Petroni, R. West, [GenIE: Generative information extraction](#), in: Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Association for Computational Linguistics, 2022, pp. 4626–4643. [doi:10.18653/v1/2022.naacl-main.342](#).
URL <https://aclanthology.org/2022.naacl-main.342/>
- [11] J. Chen, S. Xiao, P. Zhang, K. Luo, D. Lian, Z. Liu, BGE M3-embedding: Multi-lingual, multi-functionality, multi-granularity text embeddings through self-knowledge distillation, arXiv preprint arXiv:2402.03216 (2024). [doi:10.48550/arXiv.2402.03216](#).
- [12] T. Detrmers, A. Pagnoni, A. Holtzman, L. Zettlemoyer, [QLoRA: Efficient finetuning of quantized LLMs](#), in: Advances in Neural Information Processing Systems, Vol. 36, 2023, pp. 10088–10115.
URL https://proceedings.neurips.cc/paper_files/paper/2023/hash/1feb87871436031bdc0f2beaa62a049b-Abstract-Conference.html
- [13] Qwen Team, Qwen3 technical report, arXiv preprint arXiv:2505.09388 (2025). [doi:10.48550/arXiv.2505.09388](#).
- [14] Q. Liu, X. Luo, [Large language model-based knowledge graph construction of unstructured accident reports to improve construction safety](#), in: EG-ICE 2025: AI-Driven Collaboration for Sustainable and Resilient Built Environments, University of Strathclyde Publishing, 2025, pp. 536–546. [doi:10.17868/strath.00093269](#).
URL <https://strathprints.strath.ac.uk/93269/>