

面向可审计药物-不良反应关系抽取的来源受控图谱上下文增强

Xuelin Hu, Xiaoqin Fu, Youjing Fu, Jingchao Wang*,
Ruishen Liu, Charles Jumaa Katila, Pengming Hu

摘要

医疗文本中的药物不良反应抽取需要可追溯的关系结果。图谱增强抽取可以检索有用的关联，但被检索到的关联不一定是当前句子明确陈述的事实，流畅的生成结果也往往难以追溯到支持它的源文本。本文提出来源受控的图谱上下文增强方法：仅由训练标注构建知识图谱，为经 QLoRA 适配的 Qwen3-4B 抽取器提供概念提示、源文本匹配锚点、关系先验及检索得到的语义关系模式，补充源文本与标签本体之外的信息。来源规则排除仅由当前样本支持的提示，并清空跨划分精确重叠文本的图谱上下文；与生成分离的证据门控机制则重建源跨度，检查实体接受、关系类型和端点一致性，保留具有源文本链接的输出。本文以 ADE 为主要医疗评估基准，以 CoNLL04 为通用领域补充基准，分别训练并采用统一的严格字符跨度协议评估。实验表明，PGE 在两个基准上的关系 F1 均高于匹配的纯源文本生成器，而且每个接受决定均可检查；这一关系优势在两个数据集的两次追加训练中，以及排除 CoNLL04 训练-测试精确文本重叠后仍然保持。结果表明，受控图谱上下文增强能够在提升关系抽取性能的同时，保留明确的源文本链接和可检查的接受决策，从而为安全敏感场景中的人机协同知识构建提供可审计的技术基础。

关键词：实体与关系抽取；知识图谱；来源追踪；证据锚定

1 引言

结构化信息抽取把非结构化文本转化为可检索的实体、类型化关系和下游知识对象。在安全相关应用中，仅输出形式正确的三元组并不足够，分析人员还需要知道模型识别了哪个文本片段、哪个句子支持该关系，以及最终断言经过了哪些转换。本文以医疗文本中的药物不良反应抽取为主要应用场景：即便模型正确识别了药物和不良反应，若凭空建立二者关系，仍会形成误导性记录。通用领域抽取则为不同实体类型与关系结构下的同类技术问题提供补充检验。

神经实体与关系模型已经为识别任务提供了有效方

案 [1, 2]。生成模型可以跨标签体系复用统一的结构化输出格式，但语言流畅并不保证预测对象受到输入支持 [3]。当错误三元组被写入知识图谱并供后续检索或推理使用时，其影响可能超出最初的源句。

知识图谱能够提供类型化领域先验 [4]，检索增强则可在不把全部知识固化到模型参数中的情况下使用这些先验 [5]。然而，训练句中出现过的关系只能提示模型寻找某类关联，不能证明该关系在新句中成立；图谱还可能返回当前样本自身的标注，或者泄漏跨划分的重复内容。因此，关键问题不仅是图谱上下文能否提高召回率，还包括其资格、影响和接受过程能否被控制与审计。

本文构建分阶段架构：纯源文本抽取 (SOE)、精确锚点抽取 (EAE) 和高召回图谱抽取 (HRGE) 形成输入条件匹配的生成分支；确定性关系验证器检查引用、类型和源证据；实体门控依据分支一致性、源匹配锚点或已验证关系端点接受候选；最终的来源门控抽取 (PGE) 仅组合被接受的实体及其验证关系。本文提出来源约束的图谱增强与证据门控接受机制：图谱记录可以影响候选生成，但候选必须通过明确的源文本链接与类型检查才能进入输出，从而将检索上下文的使用边界与输出接受条件分离，使两类决策均可检查。

本文采用 ADE[6] 作为主要医疗评估基准，研究含两类实体和一类关系的药物不良反应抽取任务；引入 CoNLL04[7] 作为通用领域补充基准，以其四类实体和五类有向关系考察方法在不同实体角色与关系结构下的适用性。两者均为英文句级输入，并分别训练与评估，因此本文不涉及跨数据集零样本迁移。主要贡献包括：

- 来源受控的图谱上下文增强。以训练图谱提供的概念提示、源匹配锚点、关系先验和语义关系模式补充源文本与标签本体；通过资格规则排除仅由当前样本支持的提示，并清空跨划分精确重叠文本的图谱上下文。
- 生成与接受解耦的证据门控机制。结合源跨度重建、实体选择、关系验证与端点一致性检查，使候选进入最终输出的决策具有可检查的依据。
- 受控增强有效性与组件作用的实证证据。在主要医疗基准与通用领域补充基准上验证相对匹配纯源文本生成器的关系抽取增益，在两次追加训练及精确

*通信作者：Jingchao Wang, static@zut.edu.cn

重叠排除后复核该增益，并通过消融刻画图谱上下文与接受门控对精确率和召回率的影响。

2 相关工作

2.1 联合实体与关系抽取

实体识别需要同时确定边界与类型，关系抽取还必须恢复正确且有方向的端点 [1]。CoNLL04 所代表的全局一致性建模和 SpERT 的跨度枚举联合建模是两类典型方法 [2, 7]。本文从基础编码器重新训练 SpERT，并使用相同训练划分，避免采用可能已接触开发集的任务检查点。

近年来，OneRel 将任务转化为细粒度三元组分类，UniRel 统一实体与关系交互，集合预测方法则把输出视为无序关系元组集合 [8–10]。边界组装、边界回归、位置感知、全局实体匹配和单阶段跨度解码进一步改善端点建模与误差传播 [11–16]。这些工作主要优化抽取架构；本文关注的是应用于生成候选的来源和接受政策。

GLiNER 与 GLiREL 是标签条件化的实体与关系模型 [17, 18]。它们与本地微调生成器在监督、预训练和输出构造上不同，因此本文把已实现且经训练集校准的组合列为外部基线，而不将其解释为对整个模型家族的穷尽性评价。同骨干零样本生成器用于进一步区分本地适配和图谱条件的作用。

2.2 图谱上下文与约束生成

知识图谱显式表示类型化实体和关系，检索增强则把选择后的记录加入模型上下文 [4, 5]。GenIE 用实体和关系目录约束生成式信息抽取，统一结构生成把异构抽取模式映射为通用结构化输出 [19, 20]。目录合法性与源文本支持是不同要求：一个允许出现的关系仍可能没有被当前输入陈述。因此，本文把图谱上下文视为候选先验，其资格取决于训练来源与局部源匹配。

BGE-M3 为语义模式检索提供冻结文本表示 [21]，它不是图神经网络，也不与抽取器联合优化。QLoRA 则用于紧凑适配 Qwen3 骨干 [22, 23]。二者都不直接规定候选能否进入最终断言图，本文的门控规则用于明确这一决策边界。

上述区别涉及三类决策：图谱记录是否有资格进入上下文，模型是否提出候选，以及候选是否满足输出接受规则。词表约束规定预测的形式，来源约束规定提示的出处；本文将来源约束与生成后的源链接及端点一致性检查相结合，使候选生成和确定性选择能够分别评估。

2.3 证据与安全导向的知识构建

幻觉研究强调形式良好与忠实于来源之间的差异 [3]。面向事故报告的提示式知识构建同样说明了追踪生成知识来源的必要性 [24]。ADE 为药物安全关系抽取提供可控基准；本文利用其公开关系标注评估源链接抽取和所实现的证据约束，但不把句级共现解释为临床因果证明。

因此，本文将抽取准确性与可检查性作为不同的评估目标：基准标注评估预测实体和关系，源跨度与门控决策则展示接受路径。两者的结合构成本文方法的研究重点；句级证据绑定不作为语义真实性检验，也不替代人工复核。

3 方法

3.1 任务定义

令标注语料为

$$\mathcal{D} = \{(x_i, \mathcal{E}_i, \mathcal{R}_i)\}_{i=1}^N, \quad (1)$$

其中， x_i 是由公开 token 按单空格确定性拼接得到的文本， $\mathcal{E}_i$ 与 $\mathcal{R}_i$ 分别为实体集和有向关系集。实体表示为

$$e = (b, u, y), \quad x[b : u] = m, \quad (2)$$

其中 $[b, u]$ 是字符区间， y 为类型， m 为从源文本复制的提及。关系 $r = (e_s, z, e_t)$ 具有类型化有向端点和关系标签 z 。同一字符串在不同偏移处仍是不同提及，这一约束避免仅凭规范化名称把错误位置计为正确。

对有界图谱上下文 C_i ，抽取任务定义为

$$f_\theta(x_i, C_i) = (\hat{\mathcal{E}}_i, \hat{\mathcal{R}}_i). \quad (3)$$

两个预测集合都必须先在 x_i 中重建，才能被评分或接受。令 $C_i = \emptyset$ 即得到纯源文本条件；非空上下文只是建议，不能绕过证据门控。导入基准中的关系均标为显式关系，并将源句作为证据跨度，从而使每个评估关系绑定到具体句子。

3.2 框架概览

增强发生在生成器的输入上下文中，而不是基础模型结构中：图谱提示补充纯源文本基线使用的源句与标签本体。来源控制决定哪些提示可以使用，证据门控随后决定哪些生成候选进入输出。QLoRA 是各分支共享的适配方法，不是本文提出的增强机制。图1 给出整体流程。SOE、EAE 和 HRGE 是在同一 Qwen3-4B 快照上独立训练的 QLoRA 适配器。SOE 仅使用源文本和训练集本体；EAE 接收保守概念提示；HRGE 接收有界锚点、边先验和语义关系模式。证据验证图谱抽取 (EVGE)

把关系验证器用于 HRGE；保守融合抽取（CFE）将接受实体与端点过滤后的原始 HRGE 关系组合；PGE 则使用经过验证的关系。后三者是确定性后处理，而不是额外训练的网络。部署 PGE 需要 EAE 和 HRGE 候选，SOE 只用于比较。

3.3 来源受控的图谱上下文

每个训练图谱存储提及字符串、类型、有向关系及支持它们的句子标识。若候选的唯一来源是当前训练句 d ，该候选会被排除；若还有其他支持句，则保持可用。令 $\mathcal{G}_{tr} = (\mathcal{V}_{tr}, \mathcal{A}_{tr})$ 为只由训练标注构建的图， $\pi(c)$ 为上下文项 c 的支持句标识集合，则训练样本 i 的可用池为

$$\mathcal{C}_i^{\text{elig}} = \{c \in \mathcal{C}_i^{\text{raw}} : \pi(c) \setminus \{i\} \neq \emptyset\}. \quad (4)$$

该规则排除仅由当前样本支持的提示，但不声称对聚合统计执行了完全留一重算。评估标识与训练标识分离；精确文本重叠由更严格的隔离规则处理，即清空整个图谱上下文。

EAE 使用类型平衡的精确匹配概念提示。HRGE 使用三类上下文：通过类型纯度和提及形式过滤的源匹配锚点；要求存在当前样本之外支持且两个端点都出现在源句中的类型化边先验；以及由冻结 BGE-M3 检索的语义关系模式。设 $\mathbf{H}$ 为规范化候选记录向量， $\mathbf{q}$ 为规范化源句向量，则

$$\mathbf{s} = \mathbf{H}\mathbf{q}, \quad \mathcal{I} = \text{TopK}_k\{i : s_i \geq \tau\}. \quad (5)$$

该式只负责候选排序，不负责事实接受。检索上限和阈值固定于协议文件，提示也明确说明检索对象仅为线索；精确重叠隔离具有最高优先级。

3.4 结构化生成与跨度重建

生成器输出实体标识、复制文本和类型，以及关系标识、有向端点引用、关系类型与显式状态。模型不直接计算偏移。确定性展开程序把复制的提及分配到输入句中的实际出现位置，重建字符跨度，并记录无法匹配的字符串和无效引用。这样可以把语言模型候选生成与源坐标管理分开。

推理始终使用完整的输入句和固定生成策略。失败任务以空预测计入分母，而不会被删除。实验不采用依赖标注的补救窗口或按标签选择的句子截断。

3.5 QLoRA 适配与训练目标

三个生成分支均在相同的冻结 Qwen3-4B 骨干上使用匹配的 QLoRA 配置进行适配，低秩更新应用于注意力和前馈投影。对第 ℓ 个投影，有

$$W_\ell = W_\ell^{(0)} + \frac{\alpha}{r} B_\ell A_\ell, \quad \text{rank}(B_\ell A_\ell) \leq r, \quad (6)$$

其中 $W_\ell^{(0)}$ 是冻结量化权重， r 为适配器秩， A_ℓ 和 B_ℓ 是可训练低秩因子。设 $y_{1:T}$ 是序列化目标，目标 token 的 $\omega_t = 1$ ，提示 token 的 $\omega_t = 0$ ，则优化目标为

$$\mathcal{L}(\theta) = -\frac{1}{\sum_{t=1}^T \omega_t} \sum_{t=1}^T \omega_t \log p_\theta(y_t | y_{<t}, x, \mathcal{C}). \quad (7)$$

提示 token 因而不参与损失。

3.6 来源感知的候选验证与融合

对关系标签 z ，训练标注定义允许的源类型集合 S_z 和目标类型集合 T_z 。实现的类型约束为 $y_s \in S_z$ 且 $y_t \in T_z$ ，并不额外要求每个具体类型对都曾共同出现。综合引用、标签、端点类型、显式状态和源证据检查，关系谓词为

$$V(r) = V_{\text{ref}}(r) \wedge V_{\text{label}}(r) \wedge V_{\text{type}}(r) \wedge V_{\text{status}}(r) \wedge V_{\text{evidence}}(r). \quad (8)$$

其中证据检查要求证据跨度有效，而且两个端点字符串同时位于一个源证据跨度内。验证关系集合为

$$R_V = \{r \in R_H : V(r) = 1\}. \quad (9)$$

实体门控使用三个布尔信号：

$$A(e) = A_{\text{agree}}(e) \vee A_{\text{anchor}}(e) \vee A_{\text{endpoint}}(e), \quad (10)$$

相应的接受实体集合为

$$E_A = \{e \in E_H : A(e) = 1\}. \quad (11)$$

一致性指 EAE 预测出相同的大小写折叠、空白规范化文本与类型；锚点支持要求存在同类型的源门控 HRGE 锚点；端点支持表示实体参与式(9)保留的关系。这三个信号互补但并非统计独立。句内重复的规范化文本-类型候选会被合并，关系只有在两个端点都保留时才能进入输出：

$$F(R, E) = \{(e_s, z, e_t) \in R : e_s \in E \wedge e_t \in E\}. \quad (12)$$

两种输出组合为

$$G_{\text{CFE}} = (E_A, F(R_H, E_A)), \quad (13)$$

$$G_{\text{PGE}} = (E_A, F(R_V, E_A)).$$

系统记录每个接受或拒绝决定，使原始关系融合与验证关系融合的差异可直接审计。

4 实验

实验将三个贡献点与可观察结果对应：划分重叠控制检查来源资格，合规检查评估接受规则，匹配比较和消融分析检验关系抽取增益与组件作用。




图 1: 本文的详细方法架构, 包括 ADE 与 CoNLL04 输入、数据集专属训练知识图谱、Transformer 注意力模块、SOE/EAE/HRGE QLoRA 分支, 以及基于一致性、锚点、端点、关系合法性和源证据的确定性门控。

4.1 实验设置

ADE 用于评估主要医疗应用, CoNLL04 用于通用领域补充评估。每个数据集分别构建训练图谱并适配生成器, 因此该设计检验的是经本地适配后方法在两个领域的适用性, 而不是将医疗领域训练后的模型直接迁移到通用文本。实验在统一严格跨度协议下比较 PGE 与匹配的 SOE, 并分析组件效应、训练行为、运行稳定性、规则合规性和精确重叠敏感性。双基准范围是聚焦的回顾性分析, 而不是预注册的领域代表性抽样。模型与门控设置在报告的测试评估前固定, 两次追加训练用于考察观察到的增益是否依赖于单次训练结果。

4.1.1 数据集

本文使用 SpERT 格式发布的句级 ADE 和 CoNLL04 文件。CoNLL04 保留原训练、开发和测试划分。ADE 含 3845 个训练池句子与 427 个测试句子; 依据固定标识规则从训练池划出 384 句作为开发集, 剩余 3461 句用于训练。该划分不是依据验证性能选择, 也不是文献中常见 ADE 多折结果的平均。

表1 给出从实际导入文件重新计算的统计。软件中的 document 单位是一条基准句, 而不是完整病例或新闻文章。两套数据均为英文, 因此结果不支持多语言或

跨语言结论。

ADE 包含 DRUG 与 ADVERSE EFFECT 实体和一个 ADVERSE EFFECT 关系; 导入端点方向为“不良反应到药物”, 本文不将其反转。CoNLL04 包含 LOCATION、ORGANIZATION、PERSON 和 OTHER 实体, 以及五种有向关系。表2 列出各划分的精确标签数。ADE 的单关系类别减少了关系标签间的混淆, 但实体边界、关系方向和端点配对仍是关键挑战; CoNLL04 则具有更丰富的关系类别与实体角色。这些问题促使本文将源跨度重建、类型检查与端点一致性纳入候选接受机制: 识别出合理实体并不足以确定哪些有向实体对应进入最终输出。

ADE 与 CoNLL04 训练句平均长度分别为 21.17 和 28.77, 测试均值为 21.24 和 28.94; 全划分最大长度分别为 97 和 118。这些是描述性的空白 token 数, 不是 Qwen tokenizer 数。两套导入数据中的每句话都至少含一个标注关系, 因此实验没有测量以无关句为主的开放部署流中的误报行为。

图2 报告训练标签比例和各划分句长经验累积分布。CoNLL04 的句子总体更长, 而同一数据集内训练、验证、测试曲线大体一致。

知识图谱按数据集分别构建, 且只使用训练标注。对大小写折叠并压缩空白后的源字符串执行精确重叠检查: ADE 无训练-开发或训练-测试重叠; CoNLL04 有

表 1: 实际实验划分的数据清单。长度为重建源文本的空白分词数。

Dataset	Split	Sentences	Entities	Relations	Mean length
ADE	train	3461	8717	5470	21.17
ADE	validation	384	996	627	21.82
ADE	test	427	1126	724	21.24
CoNLL04	train	922	3377	1283	28.77
CoNLL04	validation	231	893	343	30.27
CoNLL04	test	288	1079	422	28.94




图 2: 数据分布分析。(a) 各数据集实体 (E) 或关系 (R) 标签的训练集组成, 各数据集-类别组合内部比例分别归一化为 100%; (b) 训练、验证和测试划分重建句长的经验累积分布, 长度以空白 token 计。

14 个开发句和 19 个测试句与训练文本相同。系统在生成前清空这些句子的 EAE 与 HRGE 图谱上下文。由于这不能消除生成器训练时对重复文本的接触, 本文另报告排除 19 个重叠测试句后的固定预测分析, 但不声称检测了所有近重复或预训练污染。

4.1.2 基线与指标

开发集比较含六个系统; 测试表包含晋级的 SOE、PGE 和三种已完成外部比较。Qwen3-4B 零样本系统不使用本地适配, 并接入记录的源展开与关系验证器; SpERT 在同一训练划分上从基础编码器训练; GLiNER+GLiREL 使用预测实体和仅训练集校准。这些是异构配置, 而不是等算力实验。

所有主表预测由同一个公开字符跨度评估器重新评分。实体键包含精确源区间和类型, 关系键包含两个类型化有向实体键和关系标签。证据偏移必须解析到源文

本; 重复键只计一次, 无效对象作为未匹配预测, 缺失任务作为空输出。池化计数为

$$\begin{aligned}
 P &= \frac{TP}{TP + FP}, \\
 R &= \frac{TP}{TP + FN}, \\
 F_1 &= \frac{2TP}{2TP + FP + FN}.
 \end{aligned} \tag{14}$$

式(14) 在每个数据集的句子间汇总, 而不是平均逐句 F1。

4.1.3 统计分析与合规评估

统计分析对固定预测进行测试句配对 bootstrap, 并在每次重采样中重算池化 F1。百分位区间描述已完成模型对的句子抽样不确定性, 不表示训练重复变异; 区间未作多重比较校正, 也不用于调整模型或门控。

表 2: 导入文件中各划分的实体与关系标注数量。

Dataset	Kind	Label	Train	Validation	Test
ADE	Entity	ADVERSE EFFECT	4631	529	616
ADE	Entity	DRUG	4086	467	510
ADE	Relation	ADVERSE EFFECT	5470	627	724
CoNLL04	Entity	LOCATION	1219	322	427
CoNLL04	Entity	ORGANIZATION	616	170	198
CoNLL04	Entity	OTHER	455	118	133
CoNLL04	Entity	PERSON	1087	283	321
CoNLL04	Relation	KILL	179	42	47
CoNLL04	Relation	LIVE IN	330	91	100
CoNLL04	Relation	LOCATED IN	247	65	94
CoNLL04	Relation	ORGANIZATION BASED IN	271	76	105
CoNLL04	Relation	WORK FOR	256	69	76

为降低结论对单次训练结果的依赖, 本文在相同数据划分与匹配优化设置下开展两次追加训练, 报告严格跨度测试 F1 的均值与样本标准差, 考察关系抽取增益是否重复出现。这些实验检查观察到的运行稳定性, 并不意味着消除了统计依赖。

合规计数基于评估器去重前的预测对象, 将类型与引用合法性和源证据绑定分别评估。基准将整句作为证据, 因此端点共现建立的是可追溯链接, 不能证明预测关系的语义正确性; 规则合规性与基于金标准的抽取准确性据此分别报告。重叠敏感性分析同时从两个系统中排除相同的重叠测试句, 不重新训练或生成, 用于检验去除已知重复文本后增益是否仍存在。测试标注仅用于统计与评分, 不用于构造图谱提示或选择阈值。

4.2 主要结果

表3 给出统一评估器下的测试结果。ADE 上, PGE 把关系精确率从 80.62% 提升到 87.00%, 召回率从 67.82% 提升到 72.10%, 关系 F1 从 SOE 的 73.67% 提升到 78.85%; 实体 F1 基本不变 (87.97% 对 87.93%)。CoNLL04 上, 关系精确率由 54.61% 升至 62.40%, 召回率由 56.16% 升至 57.82%, 关系 F1 由 55.37% 升至 60.02%, 但实体 F1 由 83.83% 降至 83.20%。主要变化因此集中在关系, 而不是全面改善提及与识别。

图3 表明 PGE-SOE 的改善具有关系特异性: 两个数据集的关系 F1 都增加, 实体差异则接近零且其配对区间跨越零。SpERT 在已完成系统中仍具有最高

实体/关系 F1: ADE 为 91.37%/84.08%, CoNLL04 为 89.02%/69.72%。因此 PGE 优于匹配的生成基线, 却没有超过训练后的跨度模型。PGE 也优于记录的零样本和 GLiNER+GLiREL 流水线, 但这一结论只适用于当前标签映射与校准。

接受机制使 PGE 在两个测试集上的规则无效关系对象数均为零, 而 SOE 在 ADE 与 CoNLL04 上分别为 31 和 16。HRGE 相应计数已为零和 3, 说明这一结果共同涉及候选质量与后续过滤。三种系统在整句证据检查下的无支持证据对象数均为零, 因此这里观察到的区别是规则合规性, 而不是已经证实的语义幻觉减少。

排除 19 个 CoNLL04 训练-测试精确重叠句后, 剩余 269 个测试句, PGE 与 SOE 的关系 F1 分别为 59.10% 和 53.79%, 差异为 5.31 个百分点。关系优势在排除已知精确重叠后仍存在; ADE 在同一检查下没有此类重叠。

4.3 训练损失诊断

图4 展示 EAE 与 HRGE 的训练损失曲线。CoNLL04 在训练早期明显下降, 随后变化幅度减小; ADE 初始损失较低, 在波动中呈现较小的后期下降。这些轨迹描述结构化生成目标的优化过程, 抽取性能则由留出集比较单独评估。

4.4 追加运行稳定性

表4 汇总两次追加训练。ADE 上两次 PGE 关系 F1 均高于 SOE (81.20% 对 78.31%, 80.62% 对 78.06%);

表 3: 严格源字符跨度下的测试比较 (micro, %)。Qwen3-ZS 为接入记录验证器的 Qwen3-4B 零样本系统, GLiNER+GLiREL 仅使用训练集校准; 所有行均由同一评估器重新评分。加粗并标注 $\uparrow$ 的数值为各数据集内相应指标的最高值。

Dataset	System	Ent. P	Ent. R	Ent. F1	Rel. P	Rel. R	Rel. F1
ADE	Qwen3-ZS + verifier	63.83	63.32	63.58	39.36	22.24	28.42
ADE	GLiNER + GLiREL	79.30	64.65	71.23	60.31	43.23	50.36
ADE	SpERT	90.65	92.10 $\uparrow$	91.37 $\uparrow$	82.19	86.05 $\uparrow$	84.08 $\uparrow$
ADE	SOE	92.21	84.10	87.97	80.62	67.82	73.67
ADE	PGE	92.89 $\uparrow$	83.48	87.93	87.00 $\uparrow$	72.10	78.85
CoNLL04	Qwen3-ZS + verifier	48.78	53.94	51.23	30.92	19.19	23.68
CoNLL04	GLiNER + GLiREL	60.78	14.37	23.24	13.79	3.79	5.95
CoNLL04	SpERT	88.61 $\uparrow$	89.43 $\uparrow$	89.02 $\uparrow$	71.01 $\uparrow$	68.48 $\uparrow$	69.72 $\uparrow$
CoNLL04	SOE	85.83	81.93	83.83	54.61	56.16	55.37
CoNLL04	PGE	86.04	80.54	83.20	62.40	57.82	60.02




图 3: 匹配 SOE 与 PGE 的测试分析。(a) ADE 和 CoNLL04 上严格跨度实体与关系 F1; (b) PGE 减 SOE 的 F1 差异, 水平区间为固定预测的配对 95% 句子 bootstrap 区间。精确值和外部基线见表 3。

CoNLL04 的差异也为正 (58.50% 对 56.91%, 61.45% 对 60.92%)。两次运行的平均关系 F1 差异在 ADE 和 CoNLL04 上分别为 2.73 与 1.06 个百分点。相对 SOE 的关系 F1 增益因此在两个数据集的两次追加训练中均重复出现。

4.5 消融实验

消融评估图谱条件生成与后续接受阶段, 不单独隔离每一种提示通道的贡献。表 5 在开发集上区分图谱条件候选生成、关系验证与实体门控融合。HRGE 与 SOE 的比较评估图谱条件生成器整体; EVGE 与 HRGE 的比较单独检验关系验证; PGE 与 EVGE 的比较评估实体选择及端点过滤。各比较用于解释组件行为, 不依据测试结果选择变体。

ADE 上, 图谱条件使关系召回率由 SOE 的 68.26% 升至 HRGE 的 72.89%, 关系 F1 由 73.16% 升至 76.29%;

实体召回率也由 82.53% 升至 85.54%。这一共同增长与图谱提示帮助恢复相关提及和实体对的机制一致。相比之下, 精确锚点 EAE 的关系精确率较高 (80.84%), 召回率较低 (67.30%), 体现了不同分支可供融合使用的候选特征。EVGE 与 HRGE 指标相同, 表明验证器没有进一步筛选这些已满足规则的候选, 因此 ADE 的这部分收益来自候选生成, 而不是关系验证。

ADE 实体门控融合使关系精确率由 EVGE 的 80.04% 升至 PGE 的 81.39%, 召回率由 72.89% 降至 71.13%, 最终关系 F1 为 75.91%, 仍高于 SOE 2.75 个百分点, 但低于 HRGE。由于 PGE 仅保留验证候选的子集, 召回损失意味着部分正确关系失去了可接受端点。精确率收益与覆盖损失共同指出当前实体选择规则的具体局限: 它能够过滤错误候选, 但也可能拒绝正确候选。

CoNLL04 上, HRGE 关系 F1 为 58.26%, SOE 为 60.24%。更丰富的关系类别与实体角色可能使图谱提示




图 4: EAE 与 HRGE 适配器的训练损失。浅色线为每五个优化步采样的原始观测，强调曲线为十个观测点的尾随均值；对数尺度保留原始波动。

表 4: 统一严格跨度评估器下两次追加训练的测试稳定性 (micro, %, 均值 $\pm$ 样本标准差, $n = 2$)。末列为 PGE 减 SOE 的平均关系 F1。

Dataset	System	Entity F1	Relation F1	Δ relation F1
ADE	SOE	88.00 $\pm$ 0.37	78.18 $\pm$ 0.18	—
ADE	PGE	89.35 $\pm$ 0.04	80.91 $\pm$ 0.41	+2.73
CoNLL04	SOE	82.26 $\pm$ 1.91	58.92 $\pm$ 2.84	—
CoNLL04	PGE	81.75 $\pm$ 2.02	59.98 $\pm$ 2.09	+1.06

更具歧义，但本实验没有单独隔离这些因素。关系验证使精确率由 60.06% 升至 62.99%，召回率保持 56.56%，F1 升至 59.60%。在这一仅进行过滤的比较中，改善与筛除错误关系、保留正确关系的作用一致。

CoNLL04 最终融合进一步将关系精确率提升至 65.08%，召回率为 55.98%，F1 为 60.19%。相比 CFE，PGE 在相同召回率下将关系 F1 从 59.44% 提升至 60.19%，显示在相同接受实体集合内采用验证关系而非原始关系的收益。实体精确率由 HRGE 的 82.35% 升至 PGE 的 84.97%，而实体召回率由 81.52% 降至 78.50%。最终关系 F1 因而恢复了 HRGE 的大部分差距，在该开发集上接近 SOE。总体而言，消融支持候选扩展与选择性接受的互补作用，同时将端点保留确定为改善覆盖率的后续方向。

5 讨论

5.1 基准发现

第三项贡献获得两个基准测试及两次追加训练中关系 F1 相对纯源文本生成提高的支持。测试提升伴随关系精确率增加，而实体 F1 接近不变或略降，这与控制候选接受的设计目标一致。验证消融还显示图谱条件与选择规则相互作用：高召回上下文可以帮助 ADE，却不会自动改善 CoNLL04；当候选本身满足规则时，验证器也可能不发生作用。

数据分布有助于解释差异：ADE 训练规模更大、平均句子更短且只有一个关系类别；CoNLL04 训练句较少、输入更长且含五类关系。这些因素相互混杂而未被实验隔离，因此应按数据集分别报告，不能合并为单一因果解释。

回顾性收窄的双基准范围和少量追加训练限制了泛化。固定 ADE 划分不能直接与多折文献均值互换。两个语料都是英文且只含带关系句，无法证明多语言、长报告或开放流性能。缺乏上游文章标识时，句子 bootstrap

表 5: 统一严格跨度评估器下的开发集消融 (micro, %)。这些系统用于刻画固定架构, 并非额外晋级的测试系统。

Dataset	System	Ent. P	Ent. R	Ent. F1	Rel. P	Rel. R	Rel. F1
ADE	SOE	89.25	82.53	85.76	78.82	68.26	73.16
ADE	EAE	90.49	81.22	85.61	80.84	67.30	73.46
ADE	HRGE	90.35	85.54	87.88	80.04	72.89	76.29
ADE	EVGE	90.35	85.54	87.88	80.04	72.89	76.29
ADE	CFE	90.48	83.94	87.08	81.39	71.13	75.91
ADE	PGE	90.48	83.94	87.08	81.39	71.13	75.91
CoNLL04	SOE	84.94	82.08	83.49	61.33	59.18	60.24
CoNLL04	EAE	83.71	82.87	83.29	58.10	60.64	59.34
CoNLL04	HRGE	82.35	81.52	81.94	60.06	56.56	58.26
CoNLL04	EVGE	82.35	81.52	81.94	62.99	56.56	59.60
CoNLL04	CFE	84.97	78.50	81.61	63.37	55.98	59.44
CoNLL04	PGE	84.97	78.50	81.61	65.08	55.98	60.19

也不能恢复同一文章中句子间的依赖。

5.2 可审计性

前两项贡献控制抽取路径上的不同环节: 来源约束决定哪些图谱提示可以使用, 接受门控决定哪些生成候选进入输出。图谱来源说明候选为何被建议, 重建偏移说明它在源文本中的位置, 门控记录说明为何保留或拒绝。这一优势属于架构层面; 本文未开展用户研究来测量分析人员工作量、决策质量或信任, 因此不能用规则完全合规替代这些证据。

门控也会付出覆盖率成本。一致性使用规范化文本-类型对, 融合时可能合并重复提及, 而评估器仍区分偏移, 因而合法出现位置可能被删除。合法端点签名和句内共现不足以证明关系语义, 三个门控信号也不是三次独立确认。因此最终结果仍应视为待人工复核的候选断言图。

精确重叠隔离阻止已知重复文本直接获得图谱提示, 却不能消除生成器的训练暴露; 预训练组件也可能见过相关材料。当前证据无法排除这种暴露。此外, 分开的源类型集合与目标类型集合弱于观察到的联合类型对目录, 后续可进一步收紧。

5.3 安全相关意义

主要医疗应用是 ADE 上的药物安全信息抽取, CoNLL04 则补充检验通用领域关系结构。框架可向分析人员同时呈现候选关系、源句、类型化端点和接受路径来源, 供其接受、修改或拒绝。没有进入保留图谱并不意味着现实中的不良反应或其他关系不存在。

本文目标限于源链接抽取和证据路径检查。生成式

适配、SpERT 监督训练与预训练标签条件模型采用不同的训练方式。PGE 需要两个适配生成器和冻结检索, 因此参数高效适配也不能被解释为已经证明的端到端成本节省。公开数据集或模型的可用性不自动授予所有再分发与商业使用权, 仍应遵守原始许可证。

6 结论与未来工作

本文面向医疗文本中的药物不良反应抽取, 提出来源约束的图谱增强与证据门控接受机制, 并开展通用领域补充评估。该机制将候选生成和输出接受解耦: 训练来源资格控制图谱提示的使用, 源跨度重建与实体-关系检查展示保留输出的接受路径。统一严格跨度评估显示, PGE 相对 SOE 在 ADE 与 CoNLL04 上的关系 F1 分别提高 5.18 和 4.65 个百分点。排除 CoNLL04 精确训练-测试重叠后关系优势仍存在, 两次追加训练也保持正差异。消融进一步区分了图谱条件候选恢复与选择性接受的作用, 并指出端点保留中的精确率-覆盖率取舍。研究由此为面向人工复核的知识构建提供了受控、可审计的图谱增强抽取方法。

未来应在预注册的多折划分、多语言与长文档语料、以及包含大量无关句的部署式数据流上检验框架。近重复聚类可扩展当前精确重叠分析, 校准后的门控置信度与联合源-目标类型约束可改善精确率-覆盖率权衡。还需要更多训练重复、端到端延迟与资源测量, 以及分析人员研究, 才能判断可检查的接受路径是否确实降低复核成本或改善下游决策。

利益冲突声明

作者声明不存在可能影响本文工作的已知竞争性经济利益或个人关系。

数据与代码可用性

在合理请求下, 可联系通信作者 Jingchao Wang 获取支持本研究结论的数据与代码。

参考文献

- [1] Jing Li, Aixin Sun, Jianglei Han, and Chenliang Li. A survey on deep learning for named entity recognition. *IEEE Transactions on Knowledge and Data Engineering*, 34(1):50–70, 2022. doi: 10.1109/TKDE.2020.2981314.
- [2] Markus Eberts and Adrian Ulges. Span-based joint entity and relation extraction with transformer pre-training. In *ECAI 2020*. IOS Press, 2020. doi: 10.3233/FAIA200321.
- [3] Ziwei Ji, Nayeon Lee, Rita Frieske, Tiezheng Yu, Dan Su, Yan Xu, Etsuko Ishii, Ye Jin Bang, Andrea Madotto, and Pascale Fung. Survey of hallucination in natural language generation. *ACM Computing Surveys*, 55(12):1–38, 2023. doi: 10.1145/3571730.
- [4] Aidan Hogan, Eva Blomqvist, Michael Cochez, Claudia D’Amato, Gerard de Melo, Claudio Gutierrez, Sabrina Kirrane, José Emilio Labra Gayo, Roberto Navigli, Sebastian Neumaier, Axel-Cyrille Ngonga Ngomo, Axel Polleres, Sabbir M. Rashid, Anisa Rula, Lukas Schmelzeisen, Juan Sequeda, Steffen Staab, and Antoine Zimmermann. Knowledge graphs. *ACM Computing Surveys*, 54(4):1–37, 2021. doi: 10.1145/3447772.
- [5] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems*, volume 33, pages 9459–9474, 2020. URL <https://proceedings.neurips.cc/paper/2020/hash/6b493230205f780e1bc26945df7481e5-Abstract.html>.
- [6] Harsha Gurulingappa, Abdul Mateen Rajput, Angus Roberts, Juliane Fluck, Martin Hofmann-Apitius, and Luca Toldo. Development of a benchmark corpus to support the automatic extraction of drug-related adverse effects from medical case reports. *Journal of Biomedical Informatics*, 45(5): 885–892, 2012. doi: 10.1016/j.jbi.2012.04.008.
- [7] Dan Roth and Wen tau Yih. A linear programming formulation for global inference in natural language tasks. In *Proceedings of the Eighth Conference on Computational Natural Language Learning*, pages 1–8. Association for Computational Linguistics, 2004. URL <https://aclanthology.org/W04-2401/>.
- [8] Yu-Ming Shang, Heyan Huang, and Xianling Mao. OneRel: Joint entity and relation extraction with one module in one step. *Proceedings of the AAAI Conference on Artificial Intelligence*, 36(10):11285–11293, 2022. doi: 10.1609/aaai.v36i10.21379.
- [9] Wei Tang, Benfeng Xu, Yuyue Zhao, Zhendong Mao, Yifeng Liu, Yong Liao, and Haiyong Xie. UniRel: Unified representation and interaction for joint relational triple extraction. In *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*, pages 7087–7099. Association for Computational Linguistics, 2022. doi: 10.18653/v1/2022.emnlp-main.477.
- [10] Dianbo Sui, Xiangrong Zeng, Yubo Chen, Kang Liu, and Jun Zhao. Joint entity and relation extraction with set prediction networks. *IEEE Transactions on Neural Networks and Learning Systems*, 35(9):12784–12795, 2024. doi: 10.1109/TNNLS.2023.3264735.
- [11] Ruixue Tang, Yanping Chen, Yongbin Qin, Ruizhang Huang, Bo Dong, and Qinghua Zheng. Boundary assembling method for joint entity and relation extraction. *Knowledge-Based Systems*, 250: 109129, 2022. doi: 10.1016/j.knosys.2022.109129.
- [12] Ruixue Tang, Yanping Chen, Yongbin Qin, Ruizhang Huang, and Qinghua Zheng. Boundary regression model for joint entity and relation extraction. *Expert Systems with Applications*, 229: 120441, 2023. doi: 10.1016/j.eswa.2023.120441.
- [13] Tiantian Chen, Lianke Zhou, Nianbin Wang, and Xirui Chen. Joint entity and relation extraction

- with position-aware attention and relation embedding. *Applied Soft Computing*, 119:108604, 2022. doi: 10.1016/j.asoc.2022.108604.
- [14] Chenglong Zhang, Shuyong Gao, Haofen Wang, and Wenqiang Zhang. Position-aware joint entity and relation extraction with attention mechanism. In *Proceedings of the Thirty-First International Joint Conference on Artificial Intelligence*, pages 4496–4502. International Joint Conferences on Artificial Intelligence Organization, 2022. doi: 10.24963/ijcai.2022/624.
- [15] Chen Gao, Xuan Zhang, Linyu Li, Jinhong Li, Rui Zhu, Kunpeng Du, and Qiuying Ma. ERGM: A multi-stage joint entity and relation extraction with global entity match. *Knowledge-Based Systems*, 271:110550, 2023. doi: 10.1016/j.knosys.2023.110550.
- [16] Dongchen Han, Zhaoqian Zheng, Hui Zhao, Shanshan Feng, and Haiting Pang. Span-based single-stage joint entity–relation extraction model. *PLOS ONE*, 18(2):e0281055, 2023. doi: 10.1371/journal.pone.0281055.
- [17] Urchade Zaratiana, Nadi Tomeh, Pierre Holat, and Thierry Charnois. GLiNER: Generalist model for named entity recognition using bidirectional transformer. In *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pages 5364–5376. Association for Computational Linguistics, 2024. doi: 10.18653/v1/2024.naacl-long.300.
- [18] Jack Boylan, Chris Hokamp, and Demian Gholipour Ghalandari. GLiREL: Generalist model for zero-shot relation extraction. *arXiv preprint arXiv:2501.03172*, 2025. doi: 10.48550/arXiv.2501.03172.
- [19] Martin Josifoski, Nicola De Cao, Maxime Peyrard, Fabio Petroni, and Robert West. GenIE: Generative information extraction. In *Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pages 4626–4643. Association for Computational Linguistics, 2022. doi: 10.18653/v1/2022.naacl-main.342. URL <https://aclanthology.org/2022.naacl-main.342/>.
- [20] Yaojie Lu, Qing Liu, Dai Dai, Xinyan Xiao, Hongyu Lin, Xianpei Han, Le Sun, and Hua Wu. Unified structure generation for universal information extraction. In *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 5755–5772. Association for Computational Linguistics, 2022. doi: 10.18653/v1/2022.acl-long.395.
- [21] Jianlv Chen, Shitao Xiao, Peitian Zhang, Kun Luo, Defu Lian, and Zheng Liu. BGE M3-embedding: Multi-lingual, multi-functionality, multi-granularity text embeddings through self-knowledge distillation. *arXiv preprint arXiv:2402.03216*, 2024. doi: 10.48550/arXiv.2402.03216.
- [22] Tim Dettmers, Artidoro Pagnoni, Ari Holtzman, and Luke Zettlemoyer. QLoRA: Efficient finetuning of quantized LLMs. In *Advances in Neural Information Processing Systems*, volume 36, pages 10088–10115, 2023. URL https://proceedings.neurips.cc/paper_files/paper/2023/hash/1feb87871436031bdc0f2beaa62a049b-Abstract-Conference.html.
- [23] Qwen Team. Qwen3 technical report. *arXiv preprint arXiv:2505.09388*, 2025. doi: 10.48550/arXiv.2505.09388.
- [24] Qiong Liu and Xiaowei Luo. Large language model-based knowledge graph construction of unstructured accident reports to improve construction safety. In *EG-ICE 2025: AI-Driven Collaboration for Sustainable and Resilient Built Environments*, pages 536–546. University of Strathclyde Publishing, 2025. doi: 10.17868/strath.00093269. URL <https://strathprints.strath.ac.uk/93269/>.